

Request batching 驗證結果

日期：2026-05-25

分支：experiment-request-batching-validation

Observation：數據看到什麼

- 原始資料：132 個 raw CSV、run_manifest.csv、request_batching_validation_summary.csv。
- 方法：每個 case 跑 3 次 repeat，每次 150 個 benchmark frames，summary 丟掉每次前 30 個 recorded frames。
- Timing run 使用 --wg-timestamps-only；counter run 使用 --wg-metrics。
- Correctness 規則：counter run 必須符合 edges=196608、vertices=393216、stop_writes=1。process failed 的 run 不算成功優化。
- 重要限制：這次 256-shard off baseline 的 median 是 1.943 ms，不是歷史上的 ~0.99 ms。所以本報告只拿同一個 binary 的 batching on/off 做相對判斷，不更新 main path 的最佳絕對數字。

舊 unsharded branch 重現

Q2 比較 baseline 是舊版 q1_on_q2_off。

case	median ms	p90 ms	median delta vs Q2 off	correctness
scalar q1 off q2 off	39.227	40.078	+26.8%	ok
q1 on q2 off	30.948	31.669	0.0%	ok
q1 on q2 batch limit 1	41.410	42.520	+33.8%	ok
q1 on q2 batch limit 2	39.052	40.049	+26.2%	ok
q1 on q2 batch limit 4	36.279	37.218	+17.2%	ok
q1 on q2 batch limit 8	34.756	35.651	+12.3%	ok
q1 on q2 batch limit 16	34.016	34.930	+9.9%	ok

case	median ms	p90 ms	median delta vs Q2 off	correctness
q1 on q2 batch limit 32	33.708	34.636	+8.9%	ok

舊版 Q2 batching 重現了主要型態：Q2 dequeue CAS fail per ok 大幅下降，從 145.3 降到 limit 32 的 1.25，但 compute median 仍然變差。最佳 Q2 batch case 仍比 Q2 off 慢 +8.9%。

Main sharded，16-shard 高 contention case

Flags：--wg-queue-shards 16 --wg-q2-shards 16 --wg-q1-lane-pop --wg-node-c-start 72。

case	median ms	p90 ms	median delta	p90 delta	correctness
Q2 batch off	4.244	4.906	0.0%	0.0%	ok
limit 1	7.369	7.498	+73.6%	+52.8%	ok
limit 2	5.128	5.277	+20.8%	+7.6%	ok
limit 4	4.255	4.673	+0.3%	-4.7%	ok
limit 8	4.174	5.102	-1.7%	+4.0%	ok
limit 16	4.262	5.390	+0.4%	+9.9%	ok
limit 32	4.117	5.263	-3.0%	+7.3%	ok

Q2 batching 把 Q2 dequeue CAS fail per ok 從 12.16 降到大約 0.26-0.47，但沒有產生至少 10% 的 median 改善。median 有改善的兩個 case，limit 8 和 32，p90 都變差。

Main sharded，256-shard adopted default case

Flags：--wg-queue-shards 256 --wg-q2-shards 256 --wg-q1-lane-pop --wg-node-c-start 72。

case	median ms	p90 ms	median delta	p90 delta	correctness
Q2 batch off	1.943	1.969	0.0%	0.0%	ok
limit 1	n/a	n/a	n/a	n/a	failed all repeats
limit 2	n/a	n/a	n/a	n/a	failed all repeats

case	median ms	p90 ms	median delta	p90 delta	correctness
limit 4	n/a	n/a	n/a	n/a	failed all repeats
limit 8	11.711	11.755	+502.7%	+497.0%	ok
limit 16	11.428	11.466	+488.1%	+482.3%	ok
limit 32	11.278	11.303	+480.4%	+474.0%	ok

limit 1/2/4 在所有 timing 和 counter repeat 都以 code -1 結束。limit 8/16/32 correctness 正常，但約比 batching off 慢 5.8 倍。

counter 型態是主要反證：Q2 dequeue CAS fail per ok 從 0.275 降到約 0.031，但 Q2 empty dequeue per ok 從 5.83 暴增到約 116。Batch slots per batch 約只有 0.26，代表多數 batch probe 是 empty 或 underfilled。

Hypothesis：可能原因

- 舊 unsharded Q2 batching 會降低 CAS contention，但成本轉移到 empty polling、partial batch、batch coordination。即使 CAS counter 改善，end-to-end compute time 仍變差。
- 在 16-shard stress case，contention 足夠高，所以 batching 可以降低 CAS traffic；但收益太小，tail latency 也常變差。這表示 batching overhead、ready 行為、empty polling 抵消了 atomic 減量。
- 在 256-shard path，簡單 subgroup batching 不適合。Shard 太多，workgroup-local batch probe 很難穩定填滿，所以 shader 花太多時間掃 empty 或 underfilled shard batch。

Conclusion：可以確認什麼，不能確認什麼

- 舊資料的關鍵結論可重現：Q2 batching 可以降低 CAS failures，但不能降低 compute time。
- 對目前 256-shard main path，request batching not working 仍明確成立。小 limit 會 failed；較大 limit 會大幅變慢。
- 對 16-shard high-contention case，batching 不是成功優化。它可能有低 shard 診斷價值，因為會降低 CAS traffic；但不符合至少 10% median 改善且 p90 不變差的採用標準。
- 這個結果不能證明所有 wave-local architecture 都不好。它只否定這種 request/dequeue batching 形狀。

Recommendation：是否值得納入下一步主線

- 不要把 Q2 request/dequeue batching 納入 main optimized path。
- 在做不同 wave-local architecture 之前，不值得再花時間做小幅 batching tweak。失敗模式是結構性的：empty polling、partial batch、underfilled batch 佔主導。
- 保留這份資料作為 negative controlled experiment：batching reduces some atomic counters, but does not improve end-to-end compute under the accepted criteria。